

Implementasi Sistem Pra-Klasifikasi Suara Burung Menggunakan Metode Fuzzy dan Supervised Learning

M. Rifqi Dzaky Azhad*, Fathan Arya Maulana†

103012330009*, 10301230083†

rifqiazhad21@gmail.com*, fathana.mrj951@gmail.com†

IF-47-08, S1 Informatika, Fakultas Informatika

Telkom University, Bandung, Indonesia

DESKRIPSI DOKUMEN

Dokumen ini adalah laporan akhir tugas besar mata kuliah Dasar Kecerdasan Artificial. Laporan ini dibentuk oleh penulis, sebagai mahasiswa kelas IF-47-08, Program Studi S1 Informatika.

I. PENDAHULUAN

Pada bab ini, akan dibahas latar belakang, rumusan masalah, tujuan dan solusi yang ditawarkan proyek ini.

A. Latar Belakang

Penurunan populasi burung secara drastis serta kepunahan berbagai spesies, baik di Indonesia maupun di tingkat global, merupakan permasalahan konservasi yang sangat serius. Secara global, lebih dari 1.400 spesies burung terancam punah, dan populasi burung di Amerika Utara telah menurun sekitar 3 miliar individu sejak tahun 1970 [1], [2], [3]. Di Indonesia, sekitar 177 spesies burung dikategorikan sebagai terancam punah oleh IUCN, termasuk burung endemik seperti Jalak Bali (*Leucopsar rothschildi*) yang mengalami penurunan populasi drastis akibat perburuan dan hilangnya habitat alami [4].

Jika tidak segera ditanggulangi, hal ini dapat menyebabkan hilangnya keanekaragaman hayati secara permanen. Oleh karena itu, diperlukan pendekatan yang efektif untuk memahami dan mengatasi permasalahan ini, salah satunya melalui upaya pemantauan (monitoring) terhadap keberadaan dan aktivitas spesies burung.

Salah satu cara melakukan pemantauan ini adalah dengan memasang mikrofon yang dapat menangkap suara burung dan menggunakan model AI untuk mengidentifikasi suara tersebut, tetapi tantangan yang di dapat adalah cakupan wilayah yang luas dan volume data non-event. Untuk itu, diperlukan lebih dari satu mikrofon atau perangkat sensor untuk menjangkau area yang lebih besar, tetapi hal ini menimbulkan tantangan dari segi efisiensi sistem. Hal ini memunculkan kebutuhan akan model klasifikasi audio yang tidak hanya akurat tetapi juga ringan dan hemat sumber daya (resource-efficient) [4].

Salah satu solusi yang dapat diterapkan adalah dengan mengurangi beban kerja (workload) model klasifikasi melalui pendekatan prapemrosesan [5]. Mengingat sebagian besar

input berupa suara lingkungan atau non-event (background noise), sistem dapat dirancang untuk membedakan terlebih dahulu antara suara latar dan suara dengan intensitas signifikan yang memiliki potensi mengandung suara burung [6].

B. Rumusan Masalah

Monitoring langsung terhadap burung di habitat alaminya terbukti memiliki risiko mengganggu perilaku alami serta keseimbangan ekosistem spesies tersebut [2], [5]. Berdasarkan temuan lapangan, pendekatan pengamatan pasif melalui suara menggunakan mikrofon menghasilkan proses yang non-intrusif dan lebih efektif. Namun, penggunaan metode klasifikasi berbasis *supervised learning* secara langsung membutuhkan daya komputasi yang besar, waktu inferensi (*running-time*) yang lama, dan konsumsi energi yang tinggi [7], [8], yang kami identifikasi sebagai tantangan utama dalam implementasi sistem monitoring *real-time* di lapangan dengan sumber daya terbatas.

C. Tujuan Proyek

Proyek ini telah berhasil mengembangkan sistem monitoring suara burung secara *real-time* yang efisien dari sisi energi dan sumber daya komputasi. Efisiensi ini dicapai dengan mengintegrasikan *Fuzzy Inference System* pada tahap awal proses, yang berfungsi untuk menyaring segmen audio yang tidak relevan atau non-event. Segmen yang diklasifikasi sebagai suara event kemudian diklasifikasikan menggunakan model *Supervised Learning* [9], [10], sehingga beban kerja model dapat dikurangi secara signifikan dan mengurangi runtime.

D. Solusi

Solusi yang diimplementasikan dalam proyek ini adalah *pipeline* sistem monitoring pasif berbasis audio untuk mendeteksi keberadaan burung di alam liar. Sistem ini menggunakan logika fuzzy untuk melakukan pra-klasifikasi dalam menentukan segmen audio yang berpotensi mengandung suara burung. Hanya segmen tersebut yang diproses lebih lanjut menggunakan model klasifikasi berbasis *supervised learning*. Pendekatan ini terbukti mampu mengurangi beban komputasi, menurunkan konsumsi energi, dan meningkatkan efisiensi sistem monitoring secara keseluruhan [11], [12].

II. METODOLOGI

Pada bab ini disampaikan tahapan-tahapan metodologi penelitian secara sistematis, mencakup pembahasan dataset, anotasi, pra-pemrosesan data, ekstraksi fitur, exploratory data analysis, model pra-klasifikasi, serta model klasifikasi, desain sistem, dan metrik evaluasi.

A. Dataset

Dataset yang digunakan bersifat open-source dan berasal dari dua sumber utama, yaitu:

- Noise Audio Data (Kaggle) [13]: Dataset ini terdiri dari berbagai jenis suara, mulai dari suara alam hingga suara perkotaan. Dataset ini terdiri atas 50 file dengan total durasi 4 menit 10 detik. Dataset ini berguna untuk melatih dan menguji algoritma pengolahan suara pada kondisi tingkat kebisingan.
- Xeno-canto [14]: Sebuah website yang menyediakan akses ke dataset suara hewan dari seluruh dunia, khususnya suara burung dari berbagai spesies. Dataset ini terdiri atas 30 file audio dengan total durasi 11 menit 12 detik. Dataset ini sangat bermanfaat untuk pengembangan model klasifikasi suara burung.

B. Anotasi

Proses anotasi audio dilakukan secara manual menggunakan aplikasi *Sonic Visualiser* [15]. Aplikasi ini memungkinkan visualisasi spektrum frekuensi dan gelombang suara secara detail sehingga memudahkan dalam menandai bagian-bagian penting pada rekaman audio untuk keperluan analisis dan pelabelan data. Segment audio yang memiliki suara burung di berikan label 0, sedangkan yang memiliki suara keras diberikan label 1, dan yang memiliki suara hening diberikan label 2.

C. Prapemrosesan

File audio memiliki karakteristik yang berbeda-beda, dimana apabila tidak dilakukan prapemrosesan dapat menyebabkan informasi yang tidak konsisten. Prapemrosesan dilakukan sehingga model dapat melakukan klasifikasi dengan efektif. Oleh karena itu diperlukannya suatu tahap yang dapat menyamakan variasi karakteristik file-file audio ini, pada Tab. I terdapat empat tahap prapemrosesan yang dilakukan pada seluruh file audio untuk mendapatkan hasil yang konsisten.

D. Ekstraksi Fitur

Untuk memperoleh representasi numerik yang mencerminkan karakteristik akustik suatu sinyal. Fitur-fitur ini digunakan sebagai input bagi model pra-klasifikasi dan klasifikasi. Pada penelitian ini, fitur yang digunakan meliputi Root Mean Squared (RMS), Spectral Flatness, dan Mel-Frequency Cepstral Coefficients (MFCC), sebagaimana dijelaskan dalam Tabel II.

Table I: Langkah-langkah Prapemrosesan Audio

Langkah	Deskripsi
Downmixing	Mengonversi audio stereo menjadi mono dengan merata-ratakan kedua channel: $x_{mono} = \frac{x_L + x_R}{2}$
Resampling	Mengubah sample rate menjadi 48 kHz untuk standarisasi sinyal audio [16].
Padding	Menyesuaikan durasi audio agar menjadi kelipatan detik tertentu, guna mempermudah proses segmentasi.
Splitting	Membagi audio menjadi segmen berdurasi 1 detik dengan overlap 0.5 detik. Segmen ke- i dimulai pada $i \times 0.5$ detik.

Table II: Deskripsi Singkat dan Rumus Fitur Ekstraksi Audio

Fitur	Rumus
RMS	$\sqrt{\frac{1}{N} \sum_{n=1}^N x[n]^2}$
Spectral Flatness	$\frac{(\prod_{n=1}^N X[n])^{1/N}}{\frac{1}{N} \sum_{n=1}^N X[n]}$
MFCC	$DCT(\log(\text{MelFB} \cdot STFT(x) ^2))$

E. Exploratory Data Analysis

Eksplorasi data dilakukan untuk memahami distribusi dan hubungan antar fitur dalam dataset terhadap label. Fokus utama diberikan pada empat fitur penting, yaitu Root Mean Square (RMS), Spectral Flatness, MFCC Mean, dan MFCC Std, yang masing-masing merepresentasikan karakteristik berbeda dari sinyal audio.

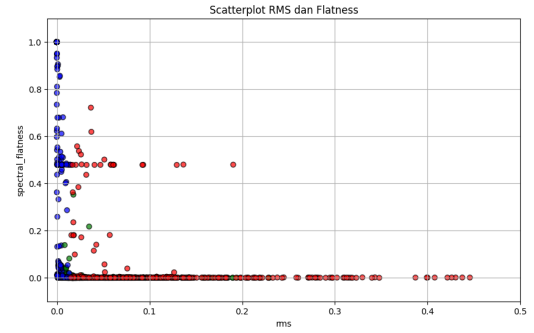


Figure 1: Scatter plot antara RMS dan Spectral Flatness berdasarkan label.

Gambar 1 menunjukkan visualisasi sebaran nilai RMS terhadap Spectral Flatness. Label berwarna biru adalah suara non-event, merah adalah suara event, dan hijau adalah suara burung.

Sementara itu, Gambar 2 menampilkan nilai korelasi yang diperoleh menggunakan koefisien Pearson. Nilai-nilai ini menunjukkan tingkat keterkaitan masing-masing fitur terhadap label, baik dalam arah positif maupun negatif.

F. Model Pra-Klasifikasi

Berikut adalah model-model yang akan diuji dalam melakukan klasifikasi antara suara event atau non-event. Di-




Figure 2: Heatmap korelasi antara empat fitur utama dengan label.

harapkan model ini dapat melakukan inferensi dengan run-ningtime yang rendah tetapi menghasilkan akurasi yang baik.

1) *FIS Mamdani*: Terdapat dua fitur input, yaitu RMS dan Flatness, RMS memiliki tiga variabel linguistik, yaitu "low", "medium", dan "high", sedangkan Flatness memiliki dua, yaitu "rigid" dan "smooth". Batas nilai universe domain RMS antara suara dengan volume rendah sampai tertinggi: $[-1, 8]$, Flatness antara suara yang stabil hingga bervariasi tinggi: $[-1, 4]$, Label yaitu suara event (1) dan non-event (2): $[1, 2]$. Range nilai tiap variabel linguistik telah disesuaikan, pada tabel III untuk RMS, Flatness, dan label hasil terdapat pada.

Table III: Fungsi Keanggotaan Fuzzy untuk Fitur dan Label Variabel

Variabel	Label Keanggotaan	Parameter Fungsi
RMS	Low	Trapezoidal (trapmf), $[-1, -1, -0.67, -0.565]$
	Medium	Triangular (trimf), $[-0.67, -0.565, -0.46]$
	High	Trapezoidal (trapmf), $[-0.565, -0.46, 8, 8]$
Flatness	Rigid	Trapezoidal (trapmf), $[-1, -1, -0.45, -0.35]$
	Smooth	Trapezoidal (trapmf), $[-0.45, -0.35, 4, 4]$
Label Variabel	Event	Triangular (trimf), $[1, 1, 1]$
	Non-event	Triangular (trimf), $[2, 2, 2]$

Berikut adalah visualisasi 3 dari Membership Function berdasarkan spesifikasi pada tabel III.

Fuzzy rule untuk RMS, Flatness, dan Label yang telah ditetapkan berdasarkan data latih. Terdapat pada IV.

Table IV: Aturan Fuzzy RMS dan Flatness

		Flatness	
		Smooth	Rigid
RMS	Low	non-event	non-event
	Medium	non-event	non-event
	High	event	event

2) *Logistic Regression*: Model linier sederhana untuk base-line. Keunggulan: Cepat, mudah diinterpretasi. Kelemahan: Kurang efektif untuk data non-linier.

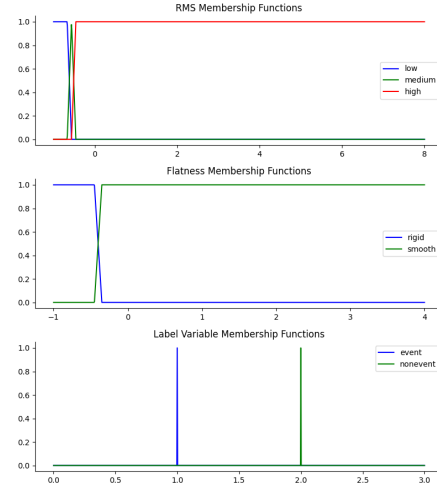


Figure 3: Membership function untuk RMS, Flatness, dan Label.

3) *Decision Tree*: Model berbasis pohon yang membagi data berdasarkan fitur. Keunggulan: Mudah divisualisasikan, non-linier. Kelemahan: Rentan overfitting.

G. Model Klasifikasi

Setelah model pra-klasifikasi menentukan segmen antara non-event dan event, apabila didapatkan segmen adalah event, segmen tersebut diklasifikasi oleh model Light Gradient Boost Machine atau Multi Layer Preceptron untuk menentukan suara non-burung atau burung.

1) *LightGBM*: Model boosting berbasis pohon. Keunggulan: Akurat, efisien, tahan overfitting. Kelemahan: Lebih kompleks, butuh tuning.

2) *Multi-Layer Perceptron*: neural network feedforward. Keunggulan: Mampu belajar pola kompleks. Kelemahan: Interpretasi sulit, butuh data besar.

H. Metrik evaluasi

Metrik evaluasi digunakan untuk mengukur performa model dalam melaksanakan tugasnya. Akurasi menjadi metrik utama, didukung oleh macro-averaged precision, recall, f1-score. Terdapat penjelasan terkait metode evaluasi pada Tab. V, confusion matrix sebagai visualisasi performa.

Table V: Perhitungan Metrik Evaluasi Model

Nama	Perhitungan
Akurasi	$\frac{TP+TN}{TP+TN+FP+FN}$
Precision (Macro)	$\frac{1}{N} \sum_{i=1}^N \frac{TP_i}{TP_i+FP_i}$
Recall (Macro)	$\frac{1}{N} \sum_{i=1}^N \frac{TP_i}{TP_i+FN_i}$
F1-Score (Macro)	$\frac{1}{N} \sum_{i=1}^N \frac{2 \cdot \text{Precision}_i \cdot \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i}$

TP: data positif diklasifikasi benar, FP: data negatif diklasifikasi positif, TN: data negatif diklasifikasi benar, FN: data positif diklasifikasi negatif, N: jumlah total kelas.

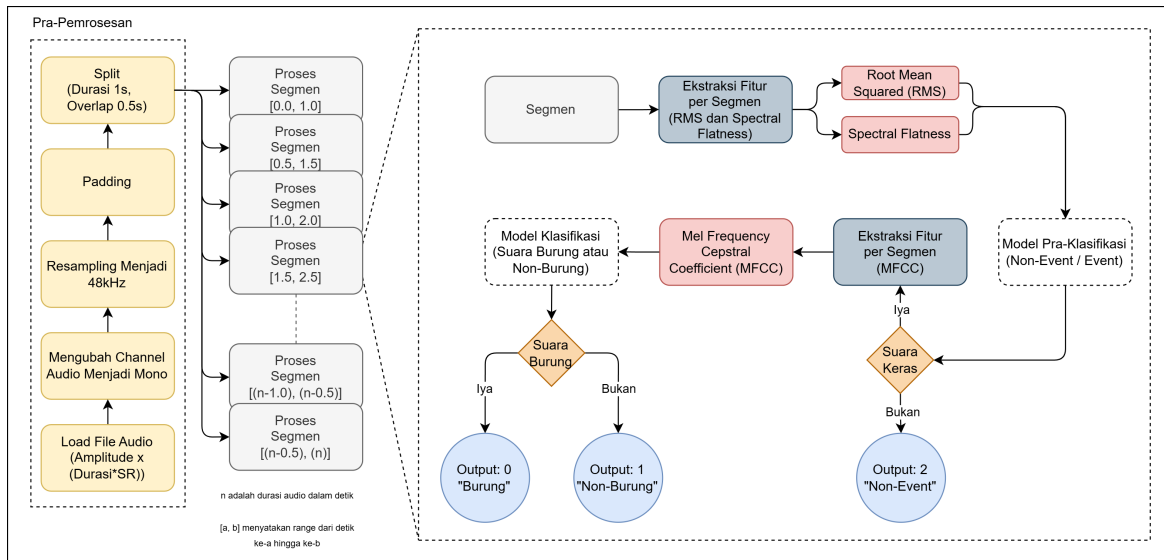


Figure 4: Alur inferensi sistem.

Table VI: Perbandingan Kinerja Model Berdasarkan Metrik dan Waktu Eksekusi

Pra-Klasifikasi	Klasifikasi	Metrik				Waktu Eksekusi (s)	
		Akurasi	Recall	Presisi	F1-Score	Rata-rata	Median
LR	MLP-2L	0.799	0.800	0.802	0.800	0.552	0.262
M-FIS	MLP-2L	0.807	0.813	0.810	0.809	0.564	0.269
DT	MLP-2L	0.813	0.830	0.822	0.815	0.523	0.239
LR	LGBM-2L	0.826	0.824	0.824	0.824	0.610	0.265
M-FIS	LGBM-2L	0.834	0.838	0.832	0.833	0.637	0.283
DT	LGBM-2L	0.836	0.850	0.839	0.835	0.589	0.285
-	MLP-3L	0.875	0.875	0.890	0.876	0.591	0.233
-	LGBM-3L	0.904	0.904	0.907	0.904	0.675	0.289

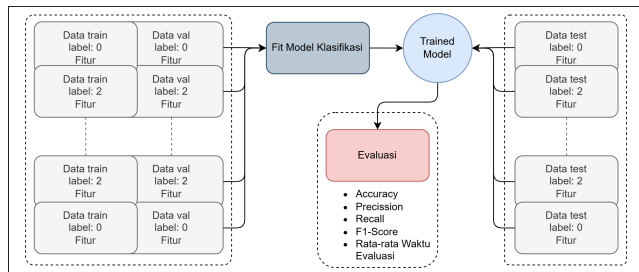


Figure 5: Alur pelatihan model.

I. Desain Sistem

Pada tahap pelatihan (training), data dibagi menjadi tiga bagian: data pelatihan (train), data validasi (val), dan data uji (test) dengan perbandingan rasio 8:1:1. Total durasi data pelatihan adalah 12 menit 17 detik, sedangkan durasi data validasi dan data pengujian masing-masing adalah 1 menit 32 detik. Selanjutnya, model dilatih menggunakan data latih dengan acuan data validasi, kemudian dievaluasi menggunakan data test, sebagaimana ditunjukkan pada Gambar 5.

Sementara itu, alur sistem secara keseluruhan dimulai dari tahap prapemrosesan, dilanjutkan dengan model pra-klasifikasi, kemudian klasifikasi, hingga akhirnya diperoleh label, sebagaimana ditunjukkan pada Gambar 4.

III. HASIL DAN ANALISIS

Bab ini menyajikan hasil dari tahapan penelitian yang telah dilakukan, yang mencakup metrik evaluasi performa model serta rasio waktu eksekusi dengan durasi file audio.

A. Hasil

Bagian ini menyajikan evaluasi kombinasi metode pra-klasifikasi dan model klasifikasi menggunakan metrik akurasi, presisi, recall, f1-score, serta rasio runtime (detik).

Penjelasan model pada tabel:

- 1) LR: Logistic Regression
- 2) M-FIS: Mamdani Fuzzy Inference System
- 3) DT: Decision Tree
- 4) MLP-2L: Multi Layer Perceptron (2 Label)
- 5) LGBM-2L: Light Gradient Boost Machine (2 Label)
- 6) MLP-3L: Multi Layer Perceptron (3 Label)

7) LGBM-3L: Light Gradient Boost Machine (3 Label)

Model MLP-2L menunjukkan peningkatan performa dengan metode pra-klasifikasi. Kombinasi DT + MLP-2L menghasilkan f1-score 0.815 dengan waktu eksekusi tercepat, rata-rata 0.523 detik dan median 0.239 detik.

Pada LGBM-2L, kombinasi DT menghasilkan f1-score 0.835, lebih tinggi dari model lainnya, meskipun waktu eksekusinya sedikit lebih lama dari DT + MLP-2L.

Tanpa pra-klasifikasi, MLP-3L dan LGBM-3L tampil unggul. LGBM-3L meraih skor tertinggi di semua metrik (0.904), namun dengan waktu eksekusi tertinggi (rata-rata 0.675 detik, median 0.289 detik).

Secara umum, pra-klasifikasi meningkatkan efisiensi waktu, terutama dengan DT. LGBM-3L tetap menjadi pilihan utama dari sisi akurasi dan f1-score, dengan kompromi pada runtime.




Figure 6: Confusion matrix model DT+MLP, Mamdani+MLP, dan LGBM-3L.

B. Analisis

LGBM-3L tanpa pra-klasifikasi mencapai performa terbaik dengan akurasi bernilai 90.4%, tetapi memiliki nilai rasio runtime terbesar, sehingga akurat tetapi tidak efisien.

Berdasarkan Gambar 6, model LGBM-3L menunjukkan performa terbaik dengan prediksi benar tertinggi untuk ketiga kelas, yakni 2460, 2328, dan 1696. Sebaliknya, kombinasi DT+MLP memiliki prediksi benar yang lebih rendah, terutama pada kelas pertama dan ketiga, masing-masing hanya sebesar 1948 dan 1348, serta menghasilkan kesalahan klasifikasi terbesar untuk kelas ketiga. Model Mamdani+MLP menunjukkan kinerja yang relatif seimbang namun masih lebih rendah dari LGBM-3L, dengan prediksi benar 2092, 2032, dan 1664 untuk masing-masing kelas. Hal ini mengonfirmasi bahwa LGBM-3L unggul dalam akurasi klasifikasi dibandingkan pendekatan lainnya.

Pra-klasifikasi sedikit menurunkan performa, namun signifikan dalam mengurangi beban komputasi. Contohnya, DT + MLP-2L menurunkan waktu rata-rata 22% dibandingkan MLP-3L. Ini menunjukkan efektivitas DT dalam menyaring data audio relevan, penting untuk aplikasi monitoring real-time. M-FIS juga memberikan peningkatan efisiensi dibandingkan dengan model LGBM-3L dan MPL-3L.

C. Kesimpulan

Pra-klasifikasi berhasil menurunkan waktu eksekusi hingga 22% (DT + MLP-2L dibandingkan MLP-3L), dengan f1-score 0.815 dan waktu rata-rata 0.523 detik, dibandingkan LGBM-3L tanpa pra-klasifikasi yang mencapai akurasi tertinggi 90.4% namun dengan waktu eksekusi rata-rata 0.675 detik. Hasil ini

menunjukkan bahwa pra-klasifikasi, terutama menggunakan Decision Tree, efektif meningkatkan efisiensi komputasi dan lebih sesuai untuk aplikasi real-time berskala besar meskipun dengan sedikit penurunan performa.

REFERENSI

- [1] A. Lees, S. Bezeng, K. Rosenberg *et al.* (2022) Global bird populations in decline, says research. Published by Manchester Metropolitan University, May 5, 2022. [Online]. Available: <https://www.mmu.ac.uk/news-and-events/news/story/?id=14791>
- [2] A. Johnston, A. D. Rodewald, M. Strimas-Mackey, T. Auer, W. M. Hochachka, A. N. Stillman, C. L. Davis, V. Ruiz-Gutierrez, A. M. Dokter, and D. Fink, "North american bird declines are greatest where species are most abundant," *Science*, vol. 388, no. 6746, pp. 532–537, May 2025. [Online]. Available: <https://www.science.org/doi/10.1126/science.adn4381>
- [3] BirdLife International, "State of the world's birds 2022," *Annual Review of Environment and Resources*, 2022, available at: <https://www.birdlife.org/worldwide/news/state-worlds-birds-2022-summary-report>.
- [4] ANTARA News. (2011, June) More Indonesian bird species nearing extinction. Accessed: 2025-05-20. [Online]. Available: <https://en.antaranews.com/news/72587/more-indonesian-bird-species-nearing-extinction>
- [5] I. Susanto. (2025, April) Status burung di Indonesia 2025, ada harapan di tengah ancaman. Accessed: 2025-05-20. [Online]. Available: <https://www.kompas.id/artikel/status-burung-di-indonesia-2025-ada-harapan-di-tengah-ancaman>
- [6] Freelancer Community. (2024, December) Understanding bird language through ai: Unlocking the secrets of avian communication. Last Modified: 20 January 2025, Accessed: 2025-05-20.
- [7] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [8] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proceedings of the 9th International Conference on Learning Representations (ICLR)*, 2021.
- [9] E. H. Mamdani, "Application of fuzzy algorithms for control of simple dynamic plant," *Proceedings of the Institution of Electrical Engineers*, vol. 121, no. 12, pp. 1585–1588, 1974.
- [10] M. Sugeno and G. Kang, "Fuzzy modeling and control of multivariable systems," in *Proceedings of the IEEE International Symposium on Fuzzy Information Processing*, 1985, pp. 262–268.
- [11] T. Samavat, M. Nazari, M. Ghalehnoie, M. A. Nasab, M. Zand, S. Padmanaban, and B. Khan, "A comparative analysis of the mamdani and sugeno fuzzy inference systems for mppt of an islanded pv system," *International Journal of Energy Research*, 2023.
- [12] A. D. Putri and A. Maulana, "Penerapan metode mamdani fuzzy logic untuk menentukan pembelian alat berat dalam proyek migas di pt smoe indonesia," *Jurnal Desain Dan Analisis Teknologi*, 2023.
- [13] J. Toshiqorgonov, "Noise audio data," <https://www.kaggle.com/datasets/javohirtoshiqorgonov/noise-audio-data>, n.d., accessed: 2025-05-10.
- [14] Xeno-canto, "Xeno-canto: Sharing bird sound recordings," <https://xeno-canto.org>, n.d., accessed: 2025-05-10.
- [15] C. Cannam, C. Landone, M. Barthet, D. Stowell, J. C. García, M. Mauch, and C. Sapp, "Sonic visualiser," London, versi 5.2.1. [Online]. Available: <https://www.sonicvisualiser.org/>
- [16] S. Kahl, C. M. Wood, M. Eibl, and H. Klinck, "Birdnet: A deep learning solution for avian diversity monitoring," *Ecological Informatics*, vol. 61, 2021.

IV. LAMPIRAN

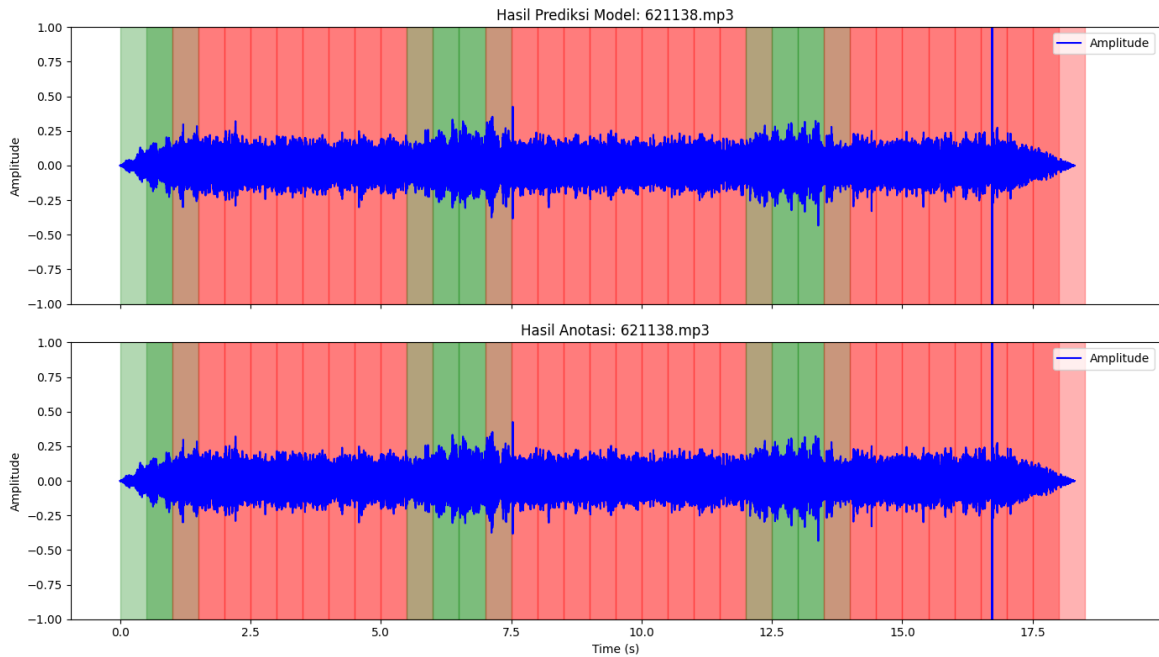


Figure 7: Contoh 1 hasil prediksi model pada file audio berisi suara burung dan berhasil dikenali dengan baik.

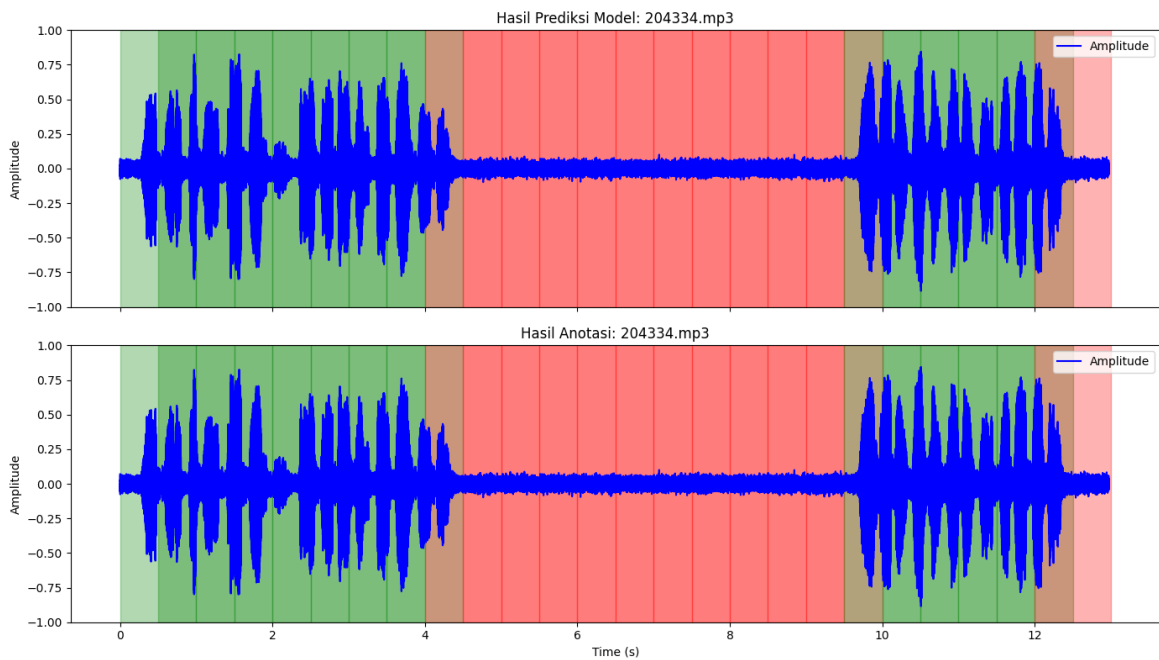


Figure 8: Contoh 2 hasil prediksi model pada file audio berisi suara burung dan berhasil dikenali dengan baik.




Figure 9: Contoh 1 hasil prediksi model pada file audio berisi suara burung yang gagal dikenali dengan baik.

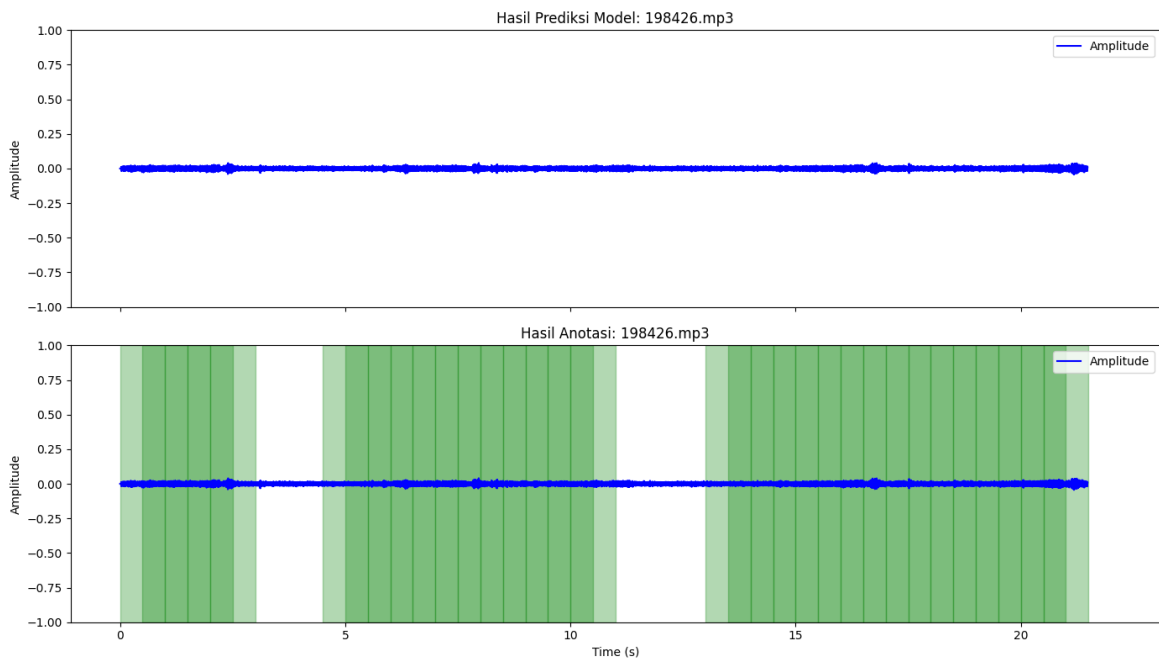


Figure 10: Contoh 2 hasil prediksi model pada file audio berisi suara burung yang gagal dikenali dengan baik.




Figure 11: Contoh 1 prediksi model pada file audio tanpa suara burung yang berhasil dikenali dengan baik.




Figure 12: Contoh 2 prediksi model pada file audio tanpa suara burung yang berhasil dikenali dengan baik.




Figure 13: Contoh prediksi model pada file audio tanpa suara burung yang gagal dikenali dengan baik.




Figure 14: Contoh prediksi model pada file audio tanpa suara burung yang terdeteksi sebagai suara burung.